Московский государственный технический университет им. Н. Э. Баумана

Курс «Технологии машинного обучения»
Отчёт по лабораторной работе №5

Выполнил:	Проверил:
Файзуллин К. Х.	Гапанюк Ю.Е.
группа ИУ5-64Б	

Дата: 21.06.25 Дата:

Подпись: Подпись:

Цель лабораторной работы: изучение ансамблей моделей машинного обучения.

Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите следующие ансамблевые модели:
 - две модели группы бэггинга (бэггинг или случайный лес или сверхслучайные деревья);
 - AdaBoost;
 - градиентный бустинг.
- 5. Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.

Ход выполнения:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.pipeline import Pipeline
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import RobustScaler, OneHotEncoder
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier, AdaBoostClassifier, ExtraTreesClassifier
from sklearn.metrics import classification_report, accuracy_score, confusion_matrix, ConfusionMatrixDisplay
```

```
[89]: data = pd.read_csv("heart.csv")
data.head()
```

[89]:

```
age sex cp trestbps chol fbs restecg thalach exang oldpeak slope ca thal target
0 63
        1 3
                  145 233
                                   0
                                         150
                                                 Ω
                                                       2.3
                                                              0 0
1
                  130
                      250
                                         187
                                                              0
2
        0 1
                  130
                      204
                                   0
                                         172
                                                 0
                                                        1.4
                                                              2
                                                                0
3
                                                              2 0
   56
       1 1
                  120 236
                            0
                                         178
                                                 Ω
                                                       8.0
                                                                      2
4
  57
        0 0
                  120 354
                           0
                                         163
                                                       0.6
                                                              2 0
```

Первичный анализ датасета

```
[91]: data.shape
[91]: (303, 14)
[92]: data.isnull().sum() # --> нет пропусков в данных
[92]: age
       \tt , chest\_pain\_type
                                      0
       resting_blood_pressure
       ,cholesterol
       ,fasting_blood_sugar
                                      0
       ,rasting_blood_sagai
,resting_electrocardiogram
,max_heart_rate_achieved
       ,exercise_induced_angina
       ,st_depression
       ,st_slope
       ,num_major_vessels
       ,thalassemia
                                      a
       ,target
                                      0
       ,dtype: int64
[93]: data.info()
       <class 'pandas.core.frame.DataFrame'>
       ,RangeIndex: 303 entries, 0 to 302
       ,Data columns (total 14 columns):
       , # Column
                                         Non-Null Count Dtype
       ,---
       , 0 age
                                         303 non-null
                                                          int64
                                         303 non-null
            sex
       , 2
            chest_pain_type
                                         303 non-null
                                                          int64
            resting_blood_pressure
                                         303 non-null
                                                          int64
       , 3
                                         303 non-null
                                                          int64
            cholesterol
      , 5
            fasting_blood_sugar
                                         303 non-null
                                                          int64
            resting_electrocardiogram 303 non-null
       , 6
                                                         int64
            max_heart_rate_achieved
                                         303 non-null
                                                          int64
            exercise_induced_angina
                                         303 non-null
                                                          int64
       , 9
            st_depression
                                         303 non-null
                                                          float64
       , 10 st_slope
                                         303 non-null
                                                          int64
       , 11 num_major_vessels
                                         303 non-null
       , 12 thalassemia
                                         303 non-null
                                                         int64
       , 13 target
                                         303 non-null
                                                         int64
       ,dtypes: float64(1), int64(13)
       ,memory usage: 33.3 KB
```

```
[94]: # Заменяем значения в столбце 'sex'
      data["sex"] = data["sex"].replace({0: "female", 1: "male"})
      # Заменяем значения в столбце 'chest_pain_type'
      data["chest_pain_type"] = data["chest_pain_type"].replace(
              0: "typical angina",
             1: "atypical angina",
             2: "non-anginal pain",
              3: "asymptomatic",
      )
      # Заменяем значения в столбце 'fasting_blood_sugar'
      data["fasting_blood_sugar"] = data["fasting_blood_sugar"].replace(
         {0: "lower than 120mg/ml", 1: "greater than 120mg/ml"}
      # Заменяем значения в столбце 'resting_electrocardiogram'
      data["resting_electrocardiogram"] = data["resting_electrocardiogram"].replace(
         {0: "normal", 1: "ST-T wave abnormality", 2: "left ventricular hypertrophy"}
      # Заменяем значения в столбце 'exercise_induced_angina'
      data["exercise_induced_angina"] = data["exercise_induced_angina"].replace(
         {0: "no", 1: "yes"}
      # Заменяем значения в столбце 'st_slope'
      data["st_slope"] = data["st_slope"].replace(
         {0: "upsloping", 1: "flat", 2: "downsloping"}
      # Заменяем значения в столбце 'thalassemia'
      data["thalassemia"] = data["thalassemia"].replace(
         {1: "fixed defect", 2: "normal", 3: "reversable defect"}
```

[95]: data.info()

[96]: data.head()

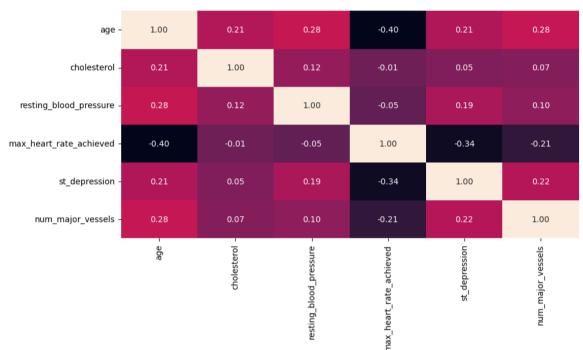
]: 0														
	age	sex	chest_pain_type	resting_blood_pressure	cholesterol	fasting_blood_sugar	$resting_electrocardiogram$	max_heart_rate_achieved	exercise_induced_angina	st_depression	st_slope	num_major_vessels	thalassemia	target
	0 63	male	asymptomatic	145	233	greater than 120mg/ml	normal	150	no	2.3	upsloping	0	fixed defect	1
	1 37	male	non-anginal pain	130	250	lower than 120mg/ml	ST-T wave abnormality	187	no	3.5	upsloping	0	normal	1
	2 41	female	atypical angina	130	204	lower than 120mg/ml	normal	172	no	1.4	downsloping	0	normal	1
	3 56	male	atypical angina	120	236	lower than 120mg/ml	ST-T wave abnormality	178	no	0.8	downsloping	0	normal	1
	4 57	female	typical angina	120	354	lower than 120mg/ml	ST-T wave abnormality	163	yes	0.6	downsloping	0	normal	1

```
[]: # Числовые признаки
num_feats = ['age', 'cholesterol', 'resting_blood_pressure', 'max_heart_rate_achieved', 'st_depression', 'num_major_vessels']

# Категориальные признаки
bin_feats = ['sex', 'fasting_blood_sugar', 'exercise_induced_angina']
nom_feats = ['chest_pain_type', 'resting_electrocardiogram', 'st_slope', 'thalassemia']
cat_feats = nom_feats + bin_feats

[100]: df_ = data[num_feats]
fig, ax = plt.subplots(figsize=(10,5))
sns.heatmap(df_.corr(method='pearson'), ax=ax, annot=True, fmt='.2f', cbar=False)
```

[100]: <Axes: >



Разделение выборки

```
[101]: x = data.drop(['target'], axis=1)
y = data['target']

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=10)
```

Масштабирование данных

Обучение моделей

Случайный лес

```
[110]: rf_cl = RandomForestClassifier(random_state=10, n_jobs=-1)
    rf_cl.fit(x_train_scaled, y_train)
```

[110]: RandomForestClassifier(n_jobs=-1, random_state=10)

In a Jupyter environment, please rerun this cell to show the HTML representation or trust the notebook.

On GitHub, the HTML representation is unable to render, please try loading this page with nbviewer.org.

RandomForestClassifier

?Documentation for RandomForestClassifieriFitted

RandomForestClassifier(n_jobs=-1, random_state=10)

Сверхслучайные деревья

```
[111]: et_cl = ExtraTreesClassifier(random_state=10, n_jobs=-1)
et_cl.fit(x_train_scaled, y_train)
```

[111]: ExtraTreesClassifier(n_jobs=-1, random_state=10)

In a Jupyter environment, please rerun this cell to show the HTML representation or trust the notebook. On GitHub, the HTML representation is unable to render, please try loading this page with nbviewer.org.

ExtraTreesClassifier

?Documentation for ExtraTreesClassifieriFitted

ExtraTreesClassifier(n_jobs=-1, random_state=10)

AdaBoost

```
[112]: ab_cl = AdaBoostClassifier(random_state=10)
ab_cl.fit(x_train_scaled, y_train)
```

[112]: AdaBoostClassifier(random_state=10)

In a Jupyter environment, please rerun this cell to show the HTML representation or trust the notebook. On GitHub, the HTML representation is unable to render, please try loading this page with nbviewer.org.

AdaBoostClassifier

 $? Documentation \ for \ AdaBoost Classifier i \textbf{Fitted}$

AdaBoostClassifier(random_state=10)

Градиентный бустинг

```
[113]: gb_cl = GradientBoostingClassifier(loss="exponential", random_state=10)
gb_cl.fit(x_train_scaled, y_train)
```

[113]: GradientBoostingClassifier(loss='exponential', random_state=10)

In a Jupyter environment, please rerun this cell to show the HTML representation or trust the notebook.

On GitHub, the HTML representation is unable to render, please try loading this page with nbviewer.org.

~

GradientBoostingClassifier

?Documentation for GradientBoostingClassifieriFitted

 $\label{loss} {\tt GradientBoostingClassifier(loss='exponential', random_state=10)}$

Оценка качества моделей

Основные метрики

Accuracy

Процент (долю в диапазоне от 0 до 1) правильно определенных классов.

Precision

$$precision = \frac{TP}{TP + FP}$$

Доля верно предсказанных классификатором положительных объектов, из всех объектов, которые классификатор верно или неверно определил как положительные.

Recall

$$recall = \frac{TP}{TP + FN}$$

Доля верно предсказанных классификатором положительных объектов, из всех действительно положительных объектов.

F1-мера

 $F_1 = 2 \cdot \frac{precision \cdot recall}{precision + recall}$

```
[114]: y_pred_rf = rf_cl.predict(x_test_scaled)
       print(classification_report(y_test, y_pred_rf))
                     precision
                                  recall f1-score support
                            0.85
                                      0.80
                                                0.82
                    0
                                                            35
                                     0.81
                   1
                           0.75
                                                0.78
                                                            26
            accuracy
                                                0.80
                                                            61
                                      0.80
           macro avg
                            0.80
                                                0.80
                                                            61
       ,weighted avg
                            0.81
                                      0.80
                                                0.80
                                                            61
[115]: y_pred_et = et_cl.predict(x_test_scaled)
       print(classification_report(y_test, y_pred_et))
                     precision
                                  recall f1-score support
                            0.85
                                      0.80
                                                0.82
                                                            35
                            0.75
                                      0.81
                                                0.78
                                                            26
                                                0.80
                                                            61
            accuracy
                                      0.80
           macro avg
                            0.80
                                                0.80
                                                            61
       ,weighted avg
                           0.81
                                      0.80
                                                0.80
                                                            61
[116]: y_pred_ab = ab_cl.predict(x_test_scaled)
       print(classification_report(y_test, y_pred_ab))
                                 recall f1-score support
                     precision
                    a
                           0.84
                                      0.77
                                                0.81
                                                            35
                   1
                            0.72
                                      0.81
                                                0.76
                                                            26
            accuracy
                                                0.79
                                                            61
           macro avg
                            0.78
                                      0.79
                                                0.78
                                                            61
       ,weighted avg
                            0.79
                                      0.79
                                                0.79
                                                            61
[117]: y_pred_gb = gb_cl.predict(x_test_scaled)
       print(classification_report(y_test, y_pred_gb))
                     precision
                                  recall f1-score support
                            0.85
                                      0.80
                            0.75
                                      0.81
                                                0.78
                                                            26
                   1
                                                            61
                                                0.80
            accuracy
                                      0.80
           macro avg
                            0.80
                                                0.80
                                                            61
        ,weighted avg
                           0.81
                                      0.80
                                                0.80
                                                            61
```



